Multi Expert Peptide Pipeline

Projet de fin d'études

Nathan Fitger Eduard Iliescu Arthur Macdonald Niels Roudeau

Université de Bordeaux
Master 2 Informatique - Intelligence Artificielle

Année 2025-2026

Plan de la présentation

1. Contexte et objectifs
2. Experts et Architecture
   - Expert Générateur de peptides
   - Expert Chimiste
   - Expert Biologiste
   - Architecture du pipeline multi-expert
3. Résultats et évaluation du pipeline
4. Discussion et perspectives

Contexte et Objectifs

Pipeline agentique multi expert pour la découverte de peptides *in silico*

in silico: réalisé par ordinateur, sans expérimentation physique.

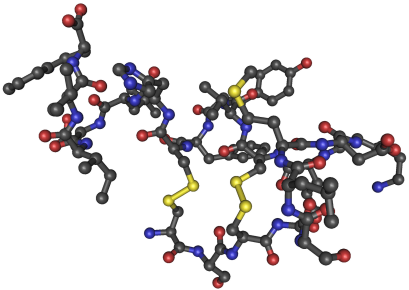

Peptide

- Chaîne composée d'au plus 50 acides aminés
- 20 acides aminés différents
- Applications: médecine, agriculture, industrie
- Exemples: insuline, antibiotiques, hormones

Processus de découverte actuel

- Découverte de peptides: criblage de bibliothèques, évolution dirigée
- Évaluation: tests biologiques, simulations moléculaires
- Itération sur les resultats pour améliorer l'efficacité de la peptides
- Coût élevé, temps long, taux de succès faible

Pipeline

Définition et rôle

Une chaîne d'étapes où la sortie d'un module devient l'entrée du suivant, permettant ainsi de répartir des tâches à différents experts.

Générateur

Modèle du générateur

- Modèle générant des séquences de peptides à partir de séquence ou propriétés souhaitées
- Entraîné sur une base de données de peptides connus et leurs propriétés
- Capable de générer des peptides avec des propriétés spécifiques (ex: propriétés chimiques)

Modèles implémentés

- VAE (Variational Autoencoder): apprend une représentation latente des peptides et génère de nouvelles séquences à partir de cette représentation
- CVAE (Conditional Variational Autoencoder): extension du VAE qui conditionne la génération sur des propriétés spécifiques (propritétés physico-chimiques, activité biologique)

Résultats du générateur

VAE et CVAE

- Génération de peptides aléatoires à l'aide du VAE

  01: IWIGRK 02: NFVFKF 03: CVKLGK 04: KRWLWR 05: LITWGK

- Génération de peptides à partir de trois propriétés différentes (longueur, cathionicity, hydrophobicity) à l'aide du CVAE

  01: KRACLIRRLR 02: LRWRWKPIAL 03: RLLKRRVIKR 04: VRLFLLPVLL 05: FWRLIYLKKW

Évaluation du générateur

- Évaluation de la qualité des peptides générés en comparant leurs propriétés à celles des peptides connus
- Utilisation de métriques telles que la diversité, la validité et la nouveauté des séquences générées

Chimiste

Modèle du chimiste

- Prend en entrée une ou des séquences de peptides générés par le générateur
- Prend des intervales de propriétés chimiques souhaitées
- Utilise des règles chimiques et physiques pour donner un score à la peptide à partir des intervalles et cibles séléctionnés

Propriétés chimiques évaluées

Taille de la séquence, Poids moléculaire, Charge nette, LogP (coefficient de partage octanol-eau), Hydrophobicité, Point isoélectrique...

Résultats du chimiste

- propriétées chimiques des peptides générés par le générateur
- score basé sur la distance entre les propriétés chimiques des peptides générés et les cibles de propriétés souhaitées
- si la peptide est hors des intervalles de propriétés souhaitées, le score est pénalisé

Biologiste

Modèle du biologiste

- Model d'embedding capable de représenter les peptides et leurs propriétés biologiques dans un espace latent
- Basé sur des données biologiques afin d'apprendre les relations entre la structure des peptides l'activitée biologique

Modèle utilisé

- Affinité pour une cible spécifique
- Activité antimicrobienne
- Toxicité potentielle
- Stabilité dans des conditions biologiques

Architecture du pipeline multi-expert

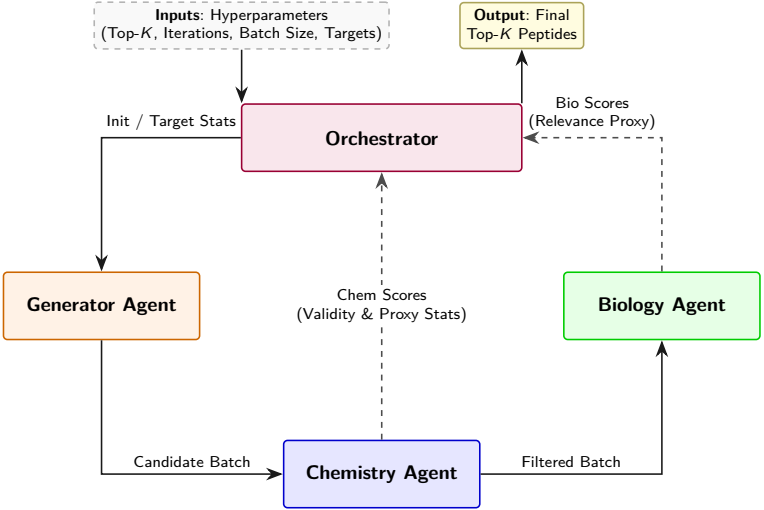

Figure: Agentic Pipeline Architecture.

Résultats: effet des itérations et du batch

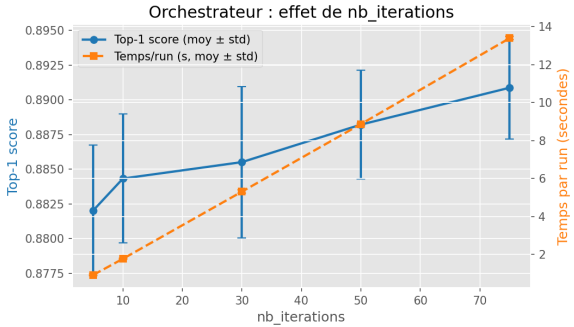

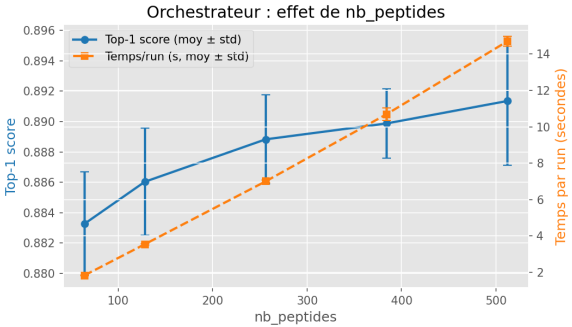

Message clé

Plus d'itérations et plus de peptides par round augmentent très légèrement le score, mais le temps d'exécution augmente fortement..

Résultats: impact de la longueur cible

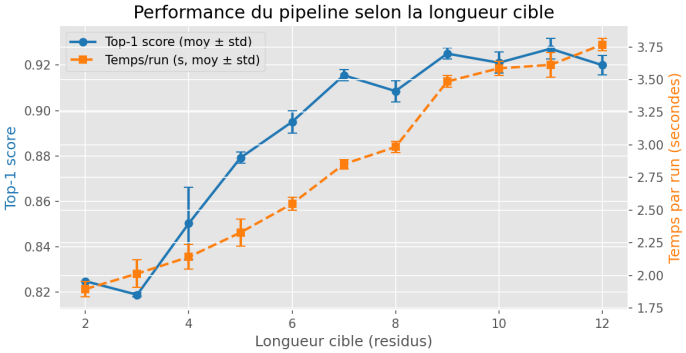

Analyse

- Les cibles très courtes (2–3) sont les plus difficiles.
- Le score augmente puis se stabilise autour de ~ 0.92 pour des longueurs plus grandes.
- Le runtime monte de façon modérée.

Pipeline vs baseline (score et diversité)

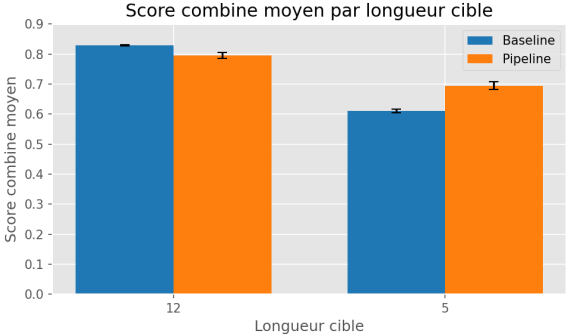

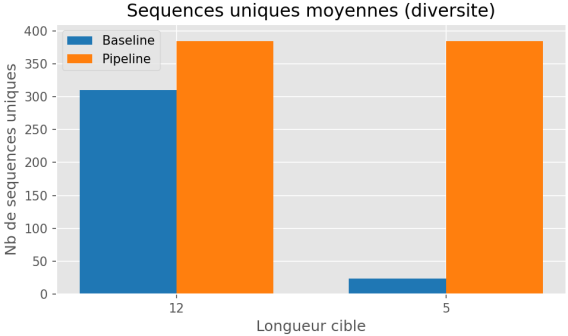

Synthèse

Le pipeline est **proche de la baseline** sur cibles longues, mais **meilleur sur cibles courtes**. Côté diversité, le pipeline génère nettement plus de séquences uniques et réduit les duplicats.

Discussion: limites actuelles

Portée des résultats

Le pipeline est un **PoC in silico**: les signaux chimie/biologie guident l'optimisation, mais ne remplacent pas une validation expérimentale.

Limites techniques principales

- Génération actuellement en **longueur fixe**.
- Qualité du contrôle dépendante de la **qualité des labels** de training.
- Score bio ESM utile pour classer, mais **pas un ground truth** d'activité.

Perspectives prioritaires

- **Biologiste spécialisé peptides**: modèle target-conditionné entraîné/fine-tuné sur données peptides validées.
- **Chimie enrichie**: ajouter des descripteurs moléculaires (ex. dérivés SMILES) en complément des propriétés séquence.
- **Entrée en langage naturel**: LLM pour traduire des objectifs utilisateurs en contraintes structurées.
- **Généralisation bio**: améliorer la robustesse sur espèces peu documentées ou émergentes.

Priorité pratique

Étape suivante la plus impactante: améliorer la fiabilité du score biologiste.

Conclusion

Merci de votre attention.

Questions ?