Multi Expert Peptide Pipeline

Projet de fin d'études

Nathan Fitger Eduard Iliescu Arthur Macdonald Niels Roudeau

Université de Bordeaux
Master 2 Informatique - Intelligence Artificielle

Année 2025-2026

Plan de la présentation

1. Contexte et objectifs
2. Experts et Architecture
   - Expert Générateur de peptides
   - Expert Chimiste
   - Expert Biologiste
   - Architecture du pipeline multi-expert
3. Résultats et évaluation du pipeline
4. limitations et défis rencontrés
5. Perspectives d'amélioration

Contexte et Objectifs

Pipeline agentique multi expert pour la découverte de peptides *in silico*

in silico : réalisé par ordinateur, sans expérimentation physique.

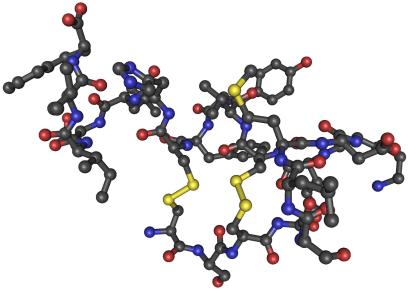

Peptide

- Chaîne composée d'au plus 50 acides aminés
- 20 acides aminés différents
- Applications : médecine, agriculture, industrie
- Exemples : insuline, antibiotiques, hormones

Processus de découverte actuel

- Découverte de peptides : criblage de bibliothèques, évolution dirigée
- Évaluation : tests biologiques, simulations moléculaires
- Itération sur les resultats pour améliorer l'efficacité de la peptides
- Coût élevé, temps long, taux de succès faible

Pipeline

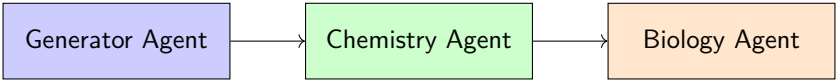

Générateur

Modèle du générateur

- Modèle générant des séquences de peptides à partir de séquence ou propriétés souhaitées
- Entraîné sur une base de données de peptides connus et leurs propriétés
- Capable de générer des peptides avec des propriétés spécifiques (ex : propriétés chimiques)

Modèles implémentés

- VAE (Variational Autoencoder) : apprend une représentation latente des peptides et génère de nouvelles séquences à partir de cette représentation
- CVAE (Conditional Variational Autoencoder) : extension du VAE qui conditionne la génération sur des propriétés spécifiques (propritétés physico-chimiques, activité biologique)

Résultats du générateur

VAE et CVAE

- Génération de peptides aléatoires à l'aide du VAE

01 : IWIGRK 02 : NFVFKF 03 : CVKLGK 04 : KRWLWR 05 : LITWGK

- Génération de peptides à partir de trois propriétés différentes (longueur, cathionicity, hydrophobicity) à l'aide du CVAE

01 : KRACLIRRLR 02 : LRWRWKPIAL 03 : RLLKRRVIKR 04 : VRLFLLPVLL 05 : FWRLIYLKKW

Évaluation du générateur

- Évaluation de la qualité des peptides générés en comparant leurs propriétés à celles des peptides connus
- Utilisation de métriques telles que la diversité, la validité et la nouveauté des séquences générées

Chimiste

Modèle du chimiste

- Prend en entrée une ou des séquences de peptides générés par le générateur
- Prend des intervales de propriétés chimiques souhaitées
- Utilise des règles chimiques et physiques pour donner un score à la peptide à partir des intervalles et cibles séléctionnés

Propriétés chimiques évaluées

Taille de la séquence, Poids moléculaire, Charge nette, LogP (coefficient de partage octanol-eau), Hydrophobicité, Point isoélectrique...

Résultats du chimiste

- propriétées chimiques des peptides générés par le générateur
- score basé sur la distance entre les propriétés chimiques des peptides générés et les cibles de propriétés souhaitées
- si la peptide est hors des intervalles de propriétés souhaitées, le score est pénalisé

Biologiste

Modèle du biologiste

- Model d'embedding capable de représenter les peptides et leurs propriétés biologiques dans un espace latent
- Basé sur des données biologiques afin d'apprendre les relations entre la structure des peptides l'activitée biologique

Modèle utilisé

- Affinité pour une cible spécifique
- Activité antimicrobienne
- Toxicité potentielle
- Stabilité dans des conditions biologiques

Architecture du pipeline multi-expert

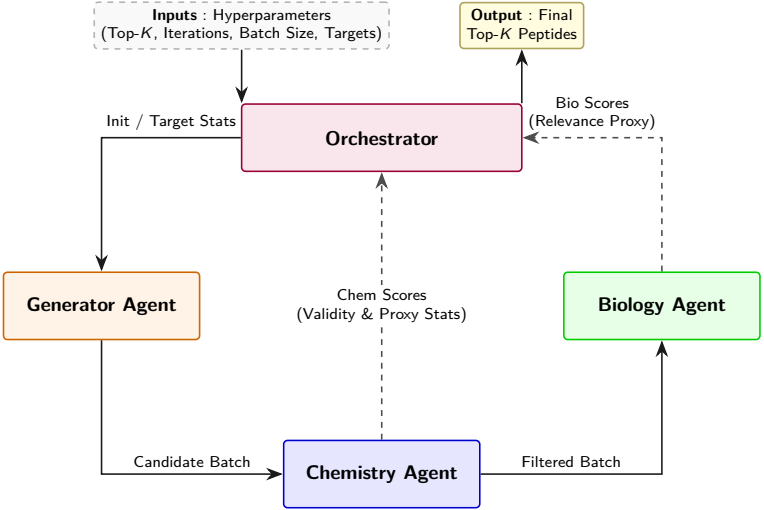

Figure – Agentic Pipeline Architecture.

Résultats et évaluation du pipeline

Du à la nature du projet, les resultats nécessitent une évaluation biologique que nous n'avons pas pu encore réaliser. Cependant les résulats sont prometteurs nottamment en ce qui concerne la partie physico-chimique du pipeline qui a permis de filtrer efficacement les peptides générés.

Limitations et défis rencontrés

- Complexité des modèles biologiste et de l'entrainement par nos propres moyens
- Difficulté à trouver des données de qualité pour l'entraînement et l'évaluation des modèles
- Difficulté à évaluer la performance du pipeline sans tests biologiques
- Besoin d'une validation expérimentale pour confirmer les résultats obtenus

Perspectives d'amélioration à l'avenir

Représentation au format SMILES.

- Utiliser une représentation chimique explicite peut enrichir la modélisation des structures.
- Meilleure précision pour la représentation 3D par la suite.
- Comparaison comparer peptide-only, SMILES-only et une approche hybride.
- Impact sur la génération/scoring.

Utilisation d'un LLM pour l'input.

- Langage naturel $\rightarrow$ contraintes structurées (propriétés cibles, seuils, priorités).
- Facilite l'utilisation du pipeline par des profils non techniques.
- Facilité de compréhension pour des contraintes biologiques.

Modèle spécialisé en peptides.

- Embeddings adaptés au domaine $\rightarrow$ mieux capturer les motifs biochimiques pertinents.
- Améliorer la qualité des candidats générés.
- Résultats plus fiables car basés sur des motifs pertinents.

Conclusion

Merci de votre attention.

Questions ?