Multi Expert Peptide Pipeline

Projet de fin d'études

Nathan Fitger Eduard Iliescu Arthur Macdonald Niels Roudeau

Supervisé par : Johan Samot (UB), Enzo Edderbah (ISM) et Akka Zemmari (UB/LABRI)

Université de Bordeaux
Master 2 Informatique — Intelligence Artificielle

Année 2025—2026

Plan de la présentation

1. Contexte et objectifs
2. Experts et Architecture
   - Expert Générateur de peptides
   - Expert Chimiste
   - Expert Biologiste
   - Architecture du pipeline multi-expert
3. Interface utilisateur
4. Résultats et évaluation du pipeline
5. Discussion et perspectives

Contexte et Objectifs

Pipeline agentique multi expert pour la découverte de peptides *in silico*

in silico: réalisé par ordinateur, sans expérimentation physique.

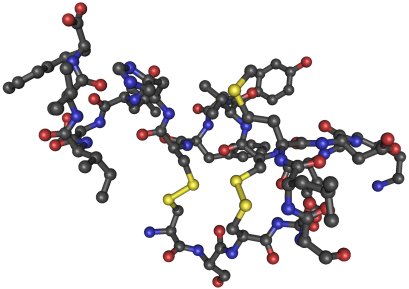

Peptide

- Chaîne composée d'au plus 50 acides aminés
- 20 acides aminés différents (A,C,D,E,F,G,H,I,K,L,M,N,P,Q,R,S,T,V,W,Y)
- Exprimé sous forme de séquence de lettres (ex: ACEFHKLMNPQY)
- Sujet initial: bactéries dentaires (ex: Streptococcus mutans)

Processus de découverte actuel

- Découverte de peptides: criblage de bibliothèques, évolution dirigée
- Propriétés à optimiser: activité biologique, stabilité, solubilité, etc.
- Évaluation: tests biologiques, simulations moléculaires
- Itération sur les resultats pour améliorer l'efficacité de la peptides
- Coût élevé, temps long, taux de succès faible

Pipeline

Définition et rôle

Une chaîne d'étapes où la sortie d'un module devient l'entrée du suivant, permettant ainsi de répartir des tâches à différents experts.

Générateur

Modèle du générateur

- Modèle fait main générant des séquences de peptides à partir de séquence ou propriétés souhaitées
- Entraîné sur une base de données de peptides connus et leurs propriétés
- Capable de générer des peptides avec des propriétés spécifiques (ex: propriétés chimiques)

Modèles implémentés

- VAE (Variational Autoencoder): apprend une représentation latente des peptides et génère de nouvelles séquences à partir de cette représentation
- CVAE (Conditional Variational Autoencoder): extension du VAE qui conditionne la génération sur des propriétés spécifiques (propritétés physico-chimiques, activité biologique)

Résultats du générateur

VAE et CVAE

- Génération de peptides aléatoires à l'aide du VAE, au format code peptidique (N-terminal vers C-terminal).

ex: IWIGRK

- Génération de peptides à partir de trois propriétés différentes (longueur, cathionicity, hydrophobicity) à l'aide du CVAE

01: KRACLIRRLR

Lettre	Composition chimique
K	Lysine (K)
R	Arginine (R)
A	Alanine (A)
C	Cysteine (C)
L	Leucine (L)
I	Isoleucine (I)

Évaluation du générateur

- Évaluation de la qualité des peptides générés en comparant leurs propriétés à celles des peptides connus

Lorsqu'on donne la sequence KLFKRWKHLFR de taille 11 et ses propriétés physico-chimiques au CVAE, il génère la sequence RKLKLFFRLLR avec des propriétés similaires.

- Utilisation de métriques telles que la diversité, la validité et la nouveauté des séquences générées

Chimiste

Modèle du chimiste

- Entrée: une ou des séquences de peptides (Format code peptidique).
- Configuration: intervalles et cibles des propriétés chimiques souhaitées
- Utilise des règles chimiques et physiques pour donner un score à la peptide à partir des intervalles et cibles séléctionnés

Propriétés chimiques évaluées

Taille de la séquence, Poids moléculaire, Charge nette, LogP (coefficient de partage octanol-eau), Hydrophobicité, Point isoélectrique...

Résultats du chimiste

- Propriétées chimiques de la ou les peptides évalués (Poids moléculaire = 530, LogP = -0.5, ...)
- Score basé sur la distance entre propriété et cible souhaité ou présence dans l'intervale.
- Présence ou non dans les intervalles de propriétés souhaitées.

Biologiste

Modèle du biologiste

- Modèle d'embedding ESM-2 → représente les peptides et leurs propriétés biologiques dans un espace latent
- Modèle **esm2_t12_35M_UR50D** par Facebook AI Research, entraîné sur une grande base de données de séquences protéiques (35M de paramètres).
- Basé sur des données biologiques afin d'apprendre les relations entre la structure des peptides l'activitée biologique

Modèle utilisé

- Affinité pour une cible spécifique (**Exemple: une souche bactérienne**)
- Activité antimicrobienne
- Toxicité potentielle
- Stabilité dans des conditions biologiques

Architecture du pipeline multi-expert

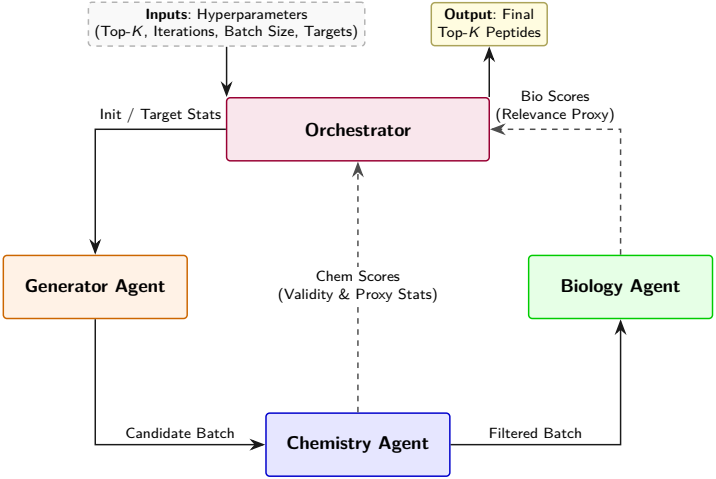

Figure: Agentic Pipeline Architecture.

Interface Graphique

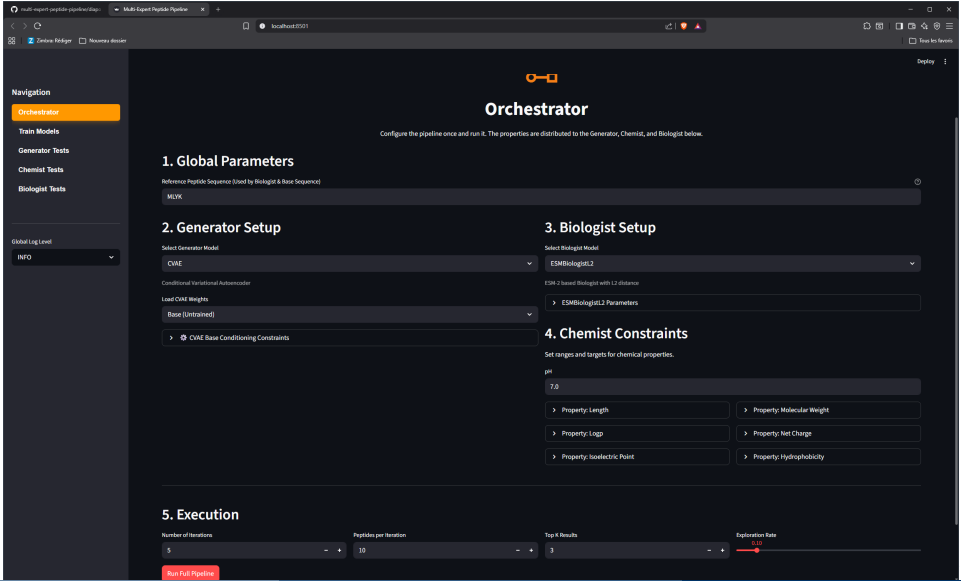

Résultats: effet des itérations et du batch

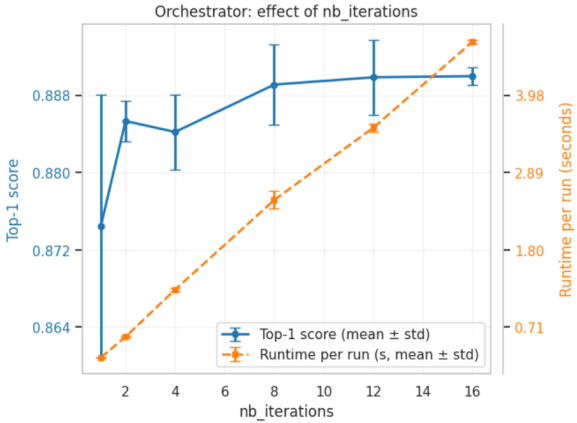

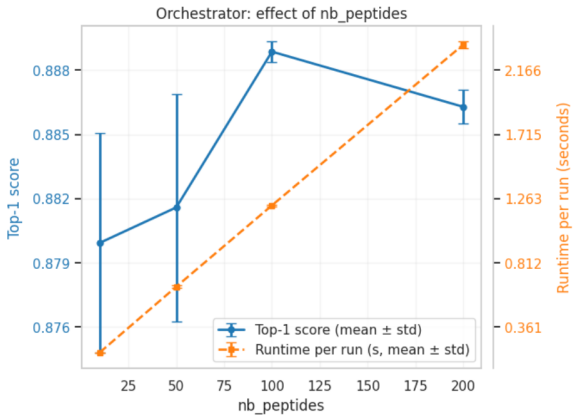

Runtime: RTX 4070 (Portable), Ryzen 7350XT, 16Go RAM

Analyse

Augmenter le budget de recherche améliore très légèrement la qualité mais rapidement le runtime, suggérant une possibilitée d'amélioration d'orchestrateur.

Résultats: impact de la longueur cible

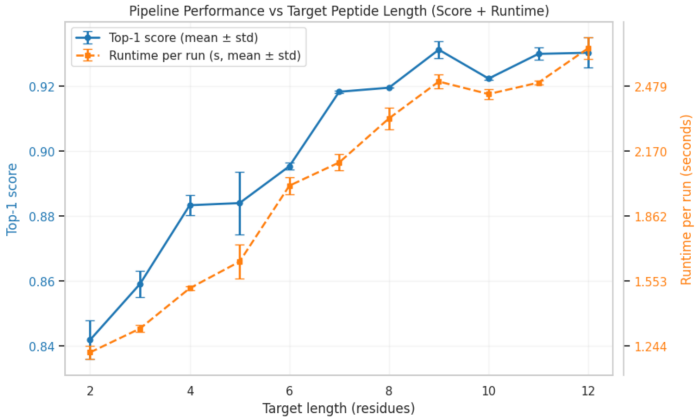

Analyse

- Les cibles très courtes (2–3) restent les plus difficiles.
- Le score remonte ensuite jusqu'à un plateau vers la longueur 11.

Runtime: RTX 4070 (Portable), Ryzen 7350XT, 16Go RAM

Attention

Les scores élevés sur des longueurs pathologiques très courtes peuvent refléter une faiblesse de l'expert biologique plus qu'une plausibilité biologique réelle.

Pipeline vs baseline selon la difficulté

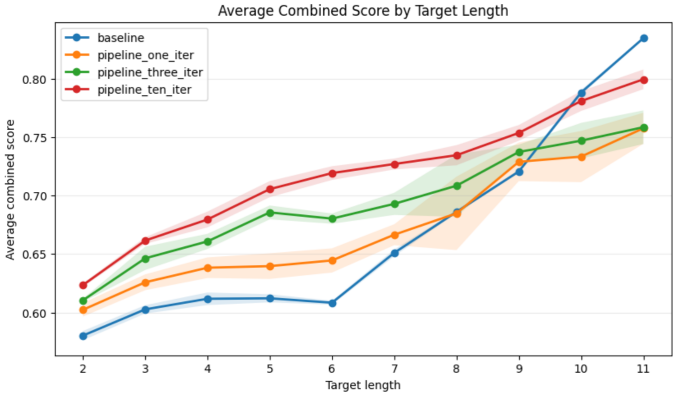

Analyse

- Sur cibles courtes (difficiles), l'itération aide clairement
- Sur cibles longues (faciles), le gain n'est pas systématique
- Plus stable avec plus d'itérations

Discussion: limites actuelles

Portée des résultats

Le pipeline est un **PoC in silico**: les signaux chimie/biologie guident l'optimisation, mais ne remplacent pas une validation expérimentale.

Limites techniques principales

- Génération actuellement en **longueur fixe**.
- Qualité du contrôle dépendante de la **qualité des labels** de training.
- Score bio ESM utile pour classer, mais **pas une vérité terrain** d'activité.

Perspectives prioritaires

- **Entrée en langage naturel**: LLM pour traduire des objectifs utilisateurs en contraintes structurées.
- **Chimie enrichie**: ajouter des descripteurs moléculaires (ex. dérivés SMILES) en complément des propriétés séquence.
- **Biologiste spécialisé peptides**: modèle target-conditionné entraîné/fine-tuné sur données peptides validées.
- **Généralisation bio**: améliorer la robustesse sur espèces peu documentées ou émergentes.

$\Longrightarrow$ Meilleure fiabilité des entrées & résultats.
$\Longrightarrow$ Utilisation par public non-expert.