Multi Expert Peptide Pipeline

Projet de fin d'études

Nathan Fitger Eduard Iliescu Arthur Macdonald Niels Roudeau

Supervisé par : Johan Samot (UB), Enzo Edderbah (ISM) et Akka Zemmari (UB/LABRI)

Université de Bordeaux
Master 2 Informatique — Intelligence Artificielle

Année 2025—2026

Plan de la présentation

1. Contexte et objectifs
2. Experts et Architecture
   - Expert Générateur de peptides
   - Expert Chimiste
   - Expert Biologiste
   - Architecture du pipeline multi-expert
3. Interface utilisateur
4. Résultats et évaluation du pipeline
5. Discussion et perspectives

Contexte et Objectifs

Pipeline agentique multi expert pour la découverte de peptides *in silico*

in silico: réalisé par ordinateur, sans expérimentation physique.

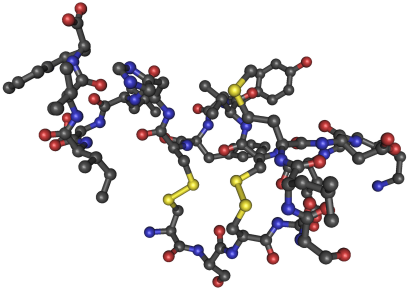

Peptide

- Chaîne composée d'au plus 50 acides aminés
- 20 acides aminés différents (A,C,D,E,F,G,H,I,K,L,M,N,P,Q,R,S,T,V,W,Y)
- Exprimé sous forme de séquence de lettres (ex: ACEFHKLMNPQY)
- Sujet initial: bactéries dentaires (ex: Streptococcus mutans)

Processus de découverte actuel

- Découverte de peptides: criblage de bibliothèques, évolution dirigée
- Propriétés à optimiser: activité biologique, stabilité, solubilité, etc.
- Évaluation: tests biologiques, simulations moléculaires
- Itération sur les resultats pour améliorer l'efficacité de la peptides
- Coût élevé, temps long, taux de succès faible

Pipeline

Définition et rôle

Une chaîne d'étapes où la sortie d'un module devient l'entrée du suivant, permettant ainsi de répartir des tâches à différents experts.

Générateur

Modèle du générateur

- Modèle fait main générant des séquences de peptides à partir de séquence ou propriétés souhaitées
- Entraîné sur une base de données de peptides connus et leurs propriétés
- Capable de générer des peptides avec des propriétés spécifiques (ex: propriétés chimiques)

Modèles implémentés

- VAE (Variational Autoencoder): apprend une représentation latente des peptides et génère de nouvelles séquences à partir de cette représentation
- CVAE (Conditional Variational Autoencoder): extension du VAE qui conditionne la génération sur des propriétés spécifiques (propritétés physico-chimiques, activité biologique)

Résultats du générateur

VAE et CVAE

- Génération de peptides aléatoires à l'aide du VAE, au format code peptidique (N-terminal vers C-terminal).

ex: IWIGRK

- Génération de peptides à partir de trois propriétés différentes (longueur, cathionicity, hydrophobicity) à l'aide du CVAE

01: KRACLIRRLR

Lettre	Composition chimique
K	Lysine (K)
R	Arginine (R)
A	Alanine (A)
C	Cysteine (C)
L	Leucine (L)
I	Isoleucine (I)

Évaluation du générateur

- Évaluation de la qualité des peptides générés en comparant leurs propriétés à celles des peptides connus

Lorsqu'on donne la sequence KLFKRWKHLFR de taille 11 et ses propriétés physico-chimiques au CVAE, il génère la sequence RKLKLFFRLLR avec des propriétés similaires.

- Utilisation de métriques telles que la diversité, la validité et la nouveauté des séquences générées

Chimiste

Modèle du chimiste

- Entrée: une ou des séquences de peptides (Format code peptidique).
- Configuration: intervalles et cibles des propriétés chimiques souhaitées
- Utilise des règles chimiques et physiques pour donner un score à la peptide à partir des intervalles et cibles séléctionnés

Propriétés chimiques évaluées

Taille de la séquence, Poids moléculaire, Charge nette, LogP (coefficient de partage octanol-eau), Hydrophobicité, Point isoélectrique...

Résultats du chimiste

- Propriétées chimiques de la ou les peptides évalués (Poids moléculaire = 530, LogP = -0.5, ...)
- Score basé sur la distance entre propriété et cible souhaité ou présence dans l'intervale.
- Présence ou non dans les intervalles de propriétés souhaitées.

Biologiste

Modèle du biologiste

- Modèle d'embedding ESM-2 $\rightarrow$ représente les peptides et leurs propriétés biologiques dans un espace latent
- Modèle **esm2_t12_35M_UR50D** par Facebook AI Research, entraîné sur une grande base de données de séquences protéiques (35M de paramètres).
- Basé sur des données biologiques afin d'apprendre les relations entre la structure des peptides l'activitée biologique

Modèle utilisé

- Affinité pour une cible spécifique (**Exemple: une souche bactérienne**)
- Activité antimicrobienne
- Toxicité potentielle
- Stabilité dans des conditions biologiques

Architecture du pipeline multi-expert

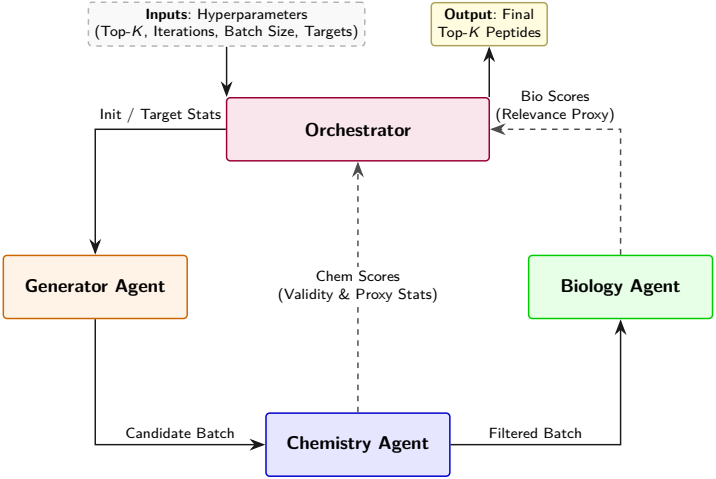

Figure: Agentic Pipeline Architecture.

Interface Graphique

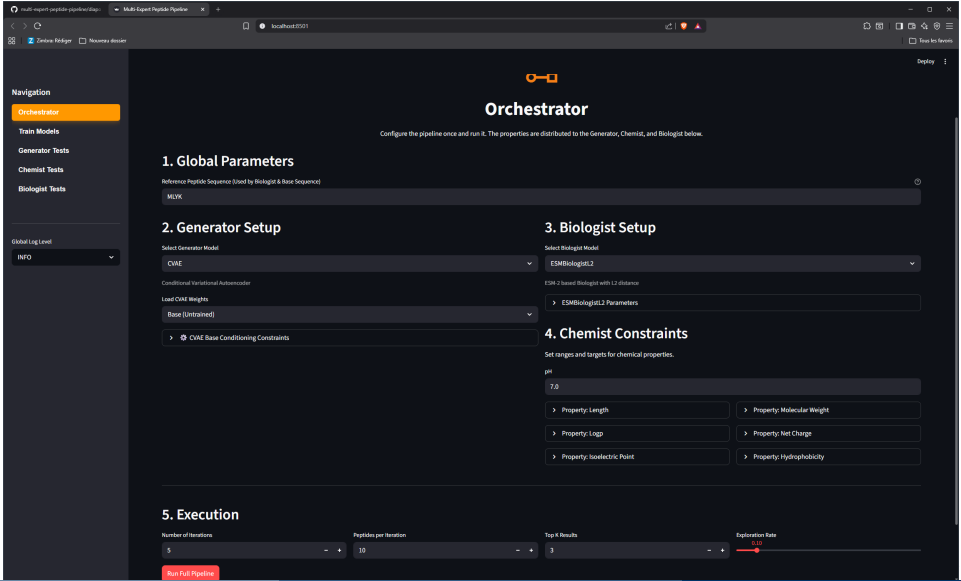

Résultats: effet des itérations et du batch

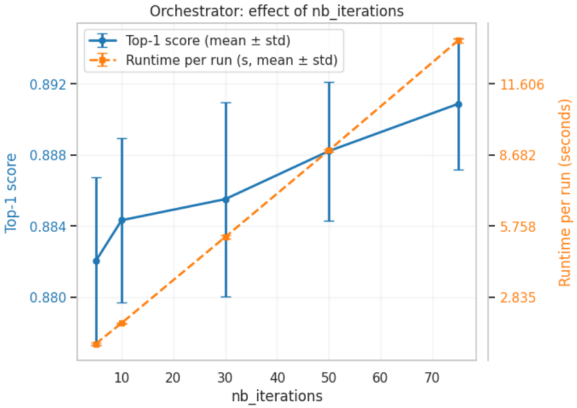

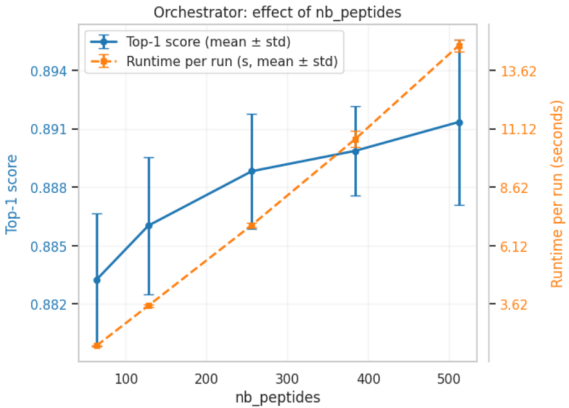

Configuration: RTX 4070 (portable), 16 GB RAM, Ryzen 7 7350XT

Message clé

Plus d'itérations et plus de peptides par round augmentent très légèrement le score, mais le temps d'exécution augmente fortement..

Résultats: impact de la longueur cible

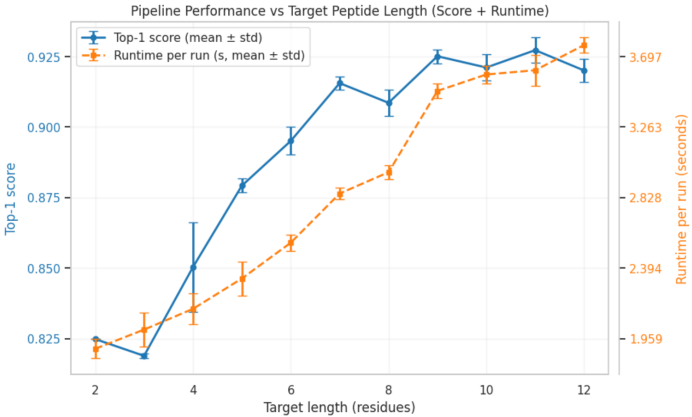

Analyse

- Les cibles très courtes (2–3) sont les plus difficiles.
- Le score augmente puis se stabilise autour de ~ 0.92 pour des longueurs plus grandes.
- Le runtime monte de façon modérée.

Pipeline vs baseline (score et diversité)

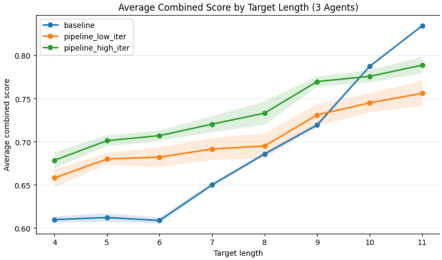

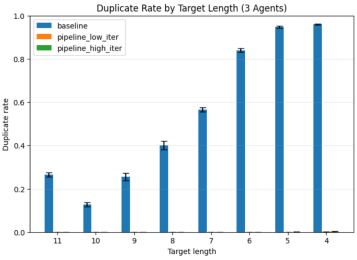

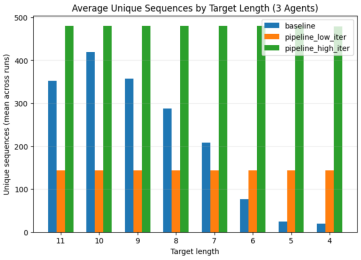

Synthèse

Le pipeline est **proche de la baseline** sur cibles longues, mais **meilleur sur cibles courtes**. Côté diversité, le pipeline génère nettement plus de séquences uniques et réduit les duplicats.

Discussion: limites actuelles

Portée des résultats

Le pipeline est un **PoC in silico**: les signaux chimie/biologie guident l'optimisation, mais ne remplacent pas une validation expérimentale.

Limites techniques principales

- Génération actuellement en **longueur fixe**.
- Qualité du contrôle dépendante de la **qualité des labels** de training.
- Score bio ESM utile pour classer, mais **pas une vérité terrain** d'activité.

Perspectives prioritaires

- **Entrée en langage naturel**: LLM pour traduire des objectifs utilisateurs en contraintes structurées.
- **Chimie enrichie**: ajouter des descripteurs moléculaires (ex. dérivés SMILES) en complément des propriétés séquence.
- **Biologiste spécialisé peptides**: modèle target-conditionné entraîné/fine-tuné sur données peptides validées.
- **Généralisation bio**: améliorer la robustesse sur espèces peu documentées ou émergentes.

$\Longrightarrow$ Meilleure fiabilité des entrées & résultats.
$\Longrightarrow$ Utilisation par public non-expert.