Multi Expert Peptide Pipeline

Projet de fin d'études

Nathan Fitger Eduard Iliescu Arthur Macdonald Niels Roudeau

Université de Bordeaux
Master 2 Informatique - Intelligence Artificielle

Année 2025-2026

Plan de la présentation

1. Contexte et objectifs
2. Architecture du pipeline multi-expert
3. Expert Générateur de peptides
4. Expert Chimiste
5. Expert Biologiste
6. Résultats et évaluation du pipeline
7. limitations et défis rencontrés

Contexte et Objectifs

L'objectif de ce projet est de mettre en place un pipeline pour découvrir et évaluer des modèles de peptides *in silico* en utilisant un enchaînement d'experts spécialisés sur certaines tâches.

in silico : réalisé par ordinateur, sans expérimentation physique.

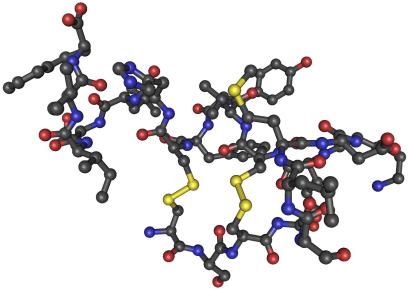

Peptide

- Chaîne composée d'au plus 50 acides aminés
- 20 acides aminés différents
- Applications : médecine, agriculture, industrie
- Exemples : insuline, antibiotiques, hormones

Processus de découverte actuel

- Découverte de peptides : criblage de bibliothèques, évolution dirigée
- Évaluation : tests biologiques, simulations moléculaires
- Itération sur les resultats pour améliorer l'efficacité de la peptides
- Coût élevé, temps long, taux de succès faible

Architecture du pipeline multi-expert

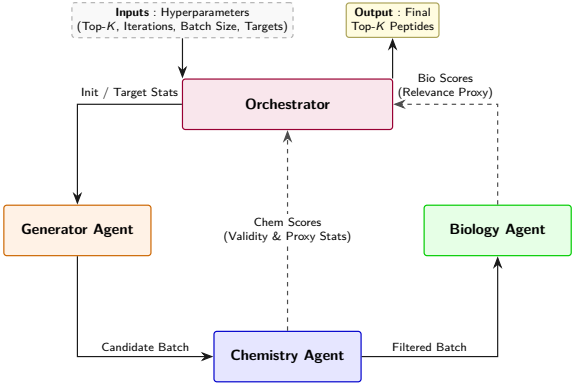

Figure – Agentic Pipeline Architecture.

Générateur

Modèle du générateur

- Modèle générant des séquences de peptides à partir de séquence ou propriétés souhaitées
- Entraîné sur une base de données de peptides connus et leurs propriétés
- Capable de générer des peptides avec des propriétés spécifiques (ex : propriétés chimiques)

Modèles implémentés

- VAE (Variational Autoencoder) : apprend une représentation latente des peptides et génère de nouvelles séquences à partir de cette représentation
- CVAE (Conditional Variational Autoencoder) : extension du VAE qui conditionne la génération sur des propriétés spécifiques (propritétés physico-chimiques, activité biologique)

Résultats du générateur

VAE et CVAE

- Génération de peptides aléatoires à l'aide du VAE

```
Peptide 01: IWIGRK  ✓
Peptide 02: NFVFKF  ✓
Peptide 03: CVKLGK  ✓
Peptide 04: LITWGK  ✓
Peptide 05: KRWLWR  ✓
Peptide 06: WRLWFR  ✓
Peptide 07: LLIPPR  ✓
Peptide 08: RRWWRF  ✓
Peptide 09: RLIWWK  ✓
Peptide 10: PWSWDK  ✓

Novel peptides  (not in training data): 9/10
Unique peptides (diversity check):      10/10
```

- Génération de peptides à partir de trois propriétés différentes (longueur, cathionicity, hydrophobicity) à l'aide du CVAE

```
Peptide 01: KRACLIRRLR  OK
Peptide 02: LRWRWKPIAL  OK
Peptide 03: RLLKRRVIKR  OK
Peptide 04: VRLFLLPVLL  OK
Peptide 05: FWRLIYLKKW  OK
Peptide 06: IRLVRKKEAR  OK
Peptide 07: GRLKSGAFSK  OK
Peptide 08: GKLRAIKIIR  OK
Peptide 09: KKWLWRWKKR  OK
Peptide 10: ILSLKRRFLK  OK
```

Évaluation du générateur

- Évaluation de la qualité des peptides générés en comparant leurs propriétés à celles des peptides connus
- Utilisation de métriques telles que la diversité, la validité et la nouveauté des séquences générées

```
validity=100.00%
diversity=100.00%
novelty_vs_training=100.00% (10/10)
```

Chimiste

Modèle du chimiste

- Expert évaluant les propriétés chimiques des peptides générés
- Basé sur des règles chimiques et des calculs mathématiques pour évaluer la validité et les propriétés des peptides
- Capable de filtrer les peptides générés en fonction de critères chimiques (ex : solubilité, stabilité)

Propriétés chimiques évaluées

- Taille de la séquence
- Poids moléculaire
- Charge nette
- LogP (coefficient de partage octanol-eau)
- Hydrophobicité
- Point isoélectrique

Biologiste

Modèle du biologiste

- Model d'embedding capable de représenter les peptides et leurs propriétés biologiques dans un espace latent
- Basé sur des données biologiques afin d'apprendre les relations entre la structure des peptides l'activitée biologique

Modèle utilisé

- Affinité pour une cible spécifique
- Activité antimicrobienne
- Toxicité potentielle
- Stabilité dans des conditions biologiques

Résultats et évaluation du pipeline

Du à la nature du projet, les resultats nécessitent une évaluation biologique que nous n'avons pas pu encore réaliser. Cependant les résulats sont prometteurs nottamment en ce qui concerne la partie physico-chimique du pipeline qui a permis de filtrer efficacement les peptides générés.

Limitations et défis rencontrés

- Manque de données biologiques pour entraîner le modèle du biologiste
- Complexité de la modélisation des interactions biologiques
- Difficulté à évaluer la performance du pipeline sans tests biologiques
- Besoin d'une validation expérimentale pour confirmer les résultats obtenus

Perspectives d'Avenir

Merci de votre attention.

Questions ?